Implementasi Metode Generalized Vector Space Model Pada Aplikasi Information Retrieval untuk Pencarian Informasi Pada Kumpulan Dokumen Teknik Elektro Di UPT BPI LIPI

Lamhot Robinson

Teknik Informatika – Universitas Komputer Indonesia
Jl. Dipatiukur 112-114 Bandung
Email : lamhot341987@gmail.com

ABSTRAK

Banyaknya dokumen yang terdapat pada UPT BPI LIPI. Dokumen-dokumen yang terkumpul berasal dari mahasiswa teknik elektro yang telah melaksanakan Praktek Kerja Lapangan. Dokumen-dokumen tersebut tidak terstruktur namun yang dibutuhkan adalah dokumen-dokumen tertentu yang akan dikaji dan menjadi bahan ajar kepada mahasiswa yang akan melaksanakan Praktek Kerja Lapangan. Maka apa yang telah diajarkan dapat dikembangkan bersama melalui Praktek Kerja Lapangan.
Proses pencarian dokumen tertentu (relevan) membutuhkan waktu yang lama untuk membuka satu persatu dokumen oleh sebab itu munculah kesulitan untuk menemubalikan dokumen tertentu (relevan), untuk mengatasinya maka dibutuhkannya suatu sistem Information Retrieval (IR) yang diharapkan mampu mempermudah pencarian dokumen yang relevan. Information Retrieval (IR) merupakan suatu metode untuk menemukan kembali data tidak terstruktur yang tersimpan pada sekumpulan dokumen dan mampu menyediakan informasi yang sesuai dengan subyek yang dibutuhkan pengguna.Algebraic Model merupakan suatu pemodelan Information Retrieval (IR) yang merepresentasikan dokumen dan query menjadi vector. Generalized Vector Space Model (GVSM) merupakan salah satu contoh yang termasuk dalam Algebraic Model dan merupakan perluasan dari Vector Space Model (VSM). Proses yang terjadi pada GVSM terbagi menjadi dua yaitu proses preprocessing (reading text, tokenization, filtration,stemming dan indexing) dan proses yang kedua adalah menghitung relevansi antara kumpulan dokumen yang telah di-preprocess dengan query yang diinginkan pengguna.
Setelah mengimplementasikan metode Generalized Vector Space Model (GVSM) pada aplikasi Information Retrieval maka dapat disimpulkan bahwa aplikasi mampu mempermudah pencarian dokumen tertentu yang mengandung kata kunci (*query*) yang dimasukan pengguna.

Kata Kunci : *Information Retrieval*, GVSM, *preprocessing*, *query*, *indexing.*

1. PENDAHULUAN

Unit Pelaksana Teknis (UPT) Balai Pengembangan Instrumentasi (BPI) Lembaga Ilmu Pengetahuan Indoensia (LIPI) (selanjutnya dikenal dengan UPT BPI LIPI) Bandung bekerjasama dengan beberapa universitas dalam bentuk praktek kerja lapangan (PKL) untuk membina kompetensi sumber daya manusia yang menunjang sistem pendidikan perguruan tinggi. PKL merupakan salah satu mata kuliah wajib pada program studi strata 1. Kegiatan ini diharapkan dapat menambah pengetahuan dan kemampuan mahasiswa teknik elektro dalam memecahkan kasus-kasus,dan menemukan solusi yang efektif dan tepat.
Banyaknya kumpulan dokumen teknik elektro yang tidak terstruktur, sementara itu yang dibutuhkan adalah dokumen-dokumen tertentu yang akan dikaji. Oleh karena itu maka dibutuhkannya suatu *Information Retrieval System* yang mampu membantu pencarian dokumen berdasarkan judul dan isi yang dikandung dari dokumen.

1.1 Information Retrieval (IR)

Information Retrieval System(Sistem Temu Balik Informasi) merupakan bagian dari bidang ilmu komputer yang bertujuan untuk pengambilan informasi dari dokumen-dokumen yang didasarkan pada isi dan konteks dari dokumen-dokumen itu sendiri. Menurut Gerald J. Kowalski di dalam bukunya "*Information Storage and Retrieval System Theory and Implementation*", sistem temu balik informasi adalah suatu sistem yang mampu melakukan penyimpanan, pencarian, dan pemeliharaan informasi. Informasi dalam konteks yang dibahas dalam buku ini dapat berupa informasi teks (termasuk data numerik dan tanggal), gambar, audio, video, dan objek multimedia lainnya.
Tujuan dari sistem *Information retrieval* adalah untuk memenuhi kebutuhan informasi pengguna dengan me-*retrieve* semua dokumen yang mungkin relevan, tetapi pada waktu yang sama me-*retrieve* sesedikit mungkin dokumen yang tidak relevan.

Sistem IR yang baik memungkinkan pengguna menentukan secara cepat dan akurat apakah isi dari dokumen yang diterima memenuhi kebutuhannya. Di dalam *information retrieval* mendapatkan dokumen yang relevan tidaklah cukup. Tujuan yang harus dipenuhi dalam suatu IR adalah bagaimana menyusun dokumen yang telah didapatkan tersebut ditampilkan terurut dari dokumen yang memiliki tingkat relevansi tinggi ke tingkat relevansi yang lebih rendah. Penyusunan urutan dokumen tersebut disebut sebagai perangkingan dokumen.

Query dalam *information retrieval* merupakan sebuah *formula* yang digunakan untuk mencari informasi yang dibutuhkan oleh *user*, dalam bentuk yang paling sederhana, sebuah *query* merupakan suatu *keywords* (kata kunci) dan dokumen yang mengandung *keywords* merupakan dokumen yang dicari dalam *information retrieval*.

Model *Information Retrieval* adalah model yang digunakan untuk melakukan pencocokan antara term-term dari *query* dengan term-term dalam *document collection*, Model yang terdapat dalam *Information retrieval* terbagi dalam 3 model besar, yaitu :

1. *Set-theoritic models*, model merepresentasikan dokumen sebagai himpunan kata atau frase. Contoh model ini ialah *standard Boolean model* dan *extended Boolean model.*
2. *Algebraic model*, model merepresentasikan dokumen dan *query* sebagai vektor *similarity* antara vektor dokumen dan vektor *query* yang direpresentasikan sebagai sebuah nilai skalar. Contoh model ini ialah *vektor space model* (model ruang vektor) , *latent semantic indexing* (LSI) dan *generalized vector space model* (GVSM).
3. *Probabilistic model*, model memperlakukan proses pengambilan dokumen sebagai sebuah *probabilistic inference.* Contoh model ini ialah penerapan teorema bayes dalam model probabilistik.

Secara garis besar terdapat dua proses besar yang dilakukan oleh sistem information retrieval yaitu preprocessing dan proses searching.

1.2 Algebraic Model

Algebraic model adalah salah satu dari 3 model besar *information retrieval*. Secara bahasa *algebraic* memiliki arti pertemuan, hubungan, atau penyelesaian. *Algebraic* atau aljabar adalah cabang ilmu matematika yang dapat dicirikan sebagai generalisasi dari bidang aritmatika. Pada *information retrieaval*, aljabar yang digunakan adalah aljabar linier yang mempelajari sistem persamaan linier dan solusinya, vektor, serta transformasi linier. Matriks dan operasinya juga merupakan hal yang berkaitan erat dengan bidang aljabar linier.

Pada *information retrieval* yang menggunakan *algebraic* model, seluruh dokumen dan *query* direpresentasikan menjadi vektor, untuk menemukan *similiarity* antara dokumen dan *query* maka nilai skalar antara vektor *query* dan vektor dokumen akan dikaitkankan sehingga muncul nilai skalar sebagai acuan pengurutan dokumen.

Hal yang perlu diperhatikan dalam pencarian informasi menggunakan *algebraic* model dari koleksi dokumen yang heterogen adalah pembobotan term. Term dapat berupa kata, frase atau unit hasil *indexing* lainnya dalam suatu dokumen yang dapat digunakan untuk mengetahui konteks dari dokumen tersebut.

1.2.1 Vector Space Model (VSM)

Setelah menghitung pembobotan, dilakukan suatu perhitungan ukuran kemiripan antar dokumen dengan *query*. Ukuran ini memungkinkan perankingan dokumen sesuai dengan kemiripan relevansinya terhadap *query*.

Vector Space Model adalah model sistem temu balik informasi yang mengibaratkan masing-masing *query* dan dokumen sebagai sebuah vektor n-dimensi. Tiap dimensi pada vektor tersebut diwakili oleh satu term. Term yang digunakan biasanya berpatokan kepada term yang ada pada *query* atau *keyword*, sehingga term yang ada pada dokumen tetapi tidak ada pada *query* biasanya diabaikan.

Model ini menentukan kemiripan (*similarity)* antara dokumen dengan *query* dengan cara merepresentasikan dokumen dan *query* masing-masing ke dalam bentuk vektor. Tiap kata yang ditemukan pada dokumen dan *query* diberi bobot dan disimpan sebagai salah satu elemen vektor.

Cosine Similarity tidak hanya digunakan untuk menghitung normalisasi panjang dokumen tapi juga menjadi salah satu ukuran kemiripan yang popular. Ukuran ini menghitung nilai kosinus sudut antara dua vektor. Jika terdapat dua vektor dokumen *dj* dan *query q*, serat *t* term diekstrak dari koleksi dokumen maka nilai kosinus antara *dj* dan *q* didefinisikan sebagai berikut:

$$\text{Sim}\left(\vec{d_j}.\vec{q}\right) = \frac{\vec{d_j}.\vec{q}}{|\vec{d_j}||\vec{q}|} = \frac{\sum_{i=1}^{t}(W_{ij} x\, W_{iq})}{\sqrt{\sum_{i=1}^{t}(W_{ij})^2 x\, \sum_{i=1}^{t}(W_{iq})^2}} \quad (1)$$

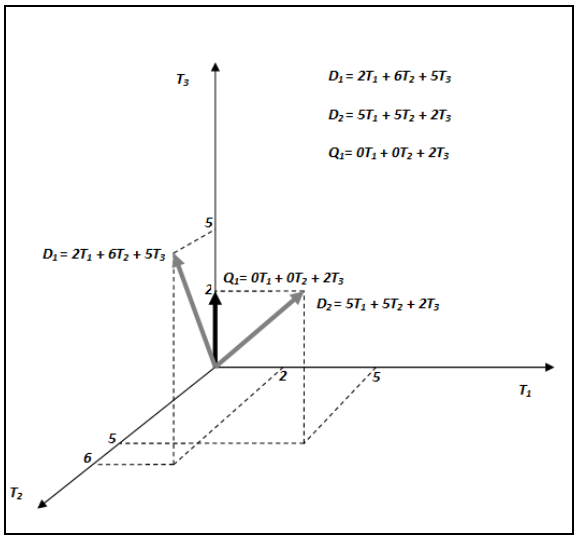

Gambar 1 Contoh Model Ruang Vector

Jika dua dokumen D1 = 2T1 + 6T2 + 5T3 dan D2 = 5T1 + 5T2 + 2T3 dan *query* Q1 = 0T1 + 0T2 + 2T3 sebagaimana diperlihatkan pada Gambar 1, berikut ini adalah nilai kosinus yang diperoleh:

$$\text{Sim}\left(\vec{d_1}.\vec{q}\right) = \frac{(2x0)+(6x0)+(5x2)}{(\sqrt{4+36+25})(\sqrt{0+0+4})} = \frac{10}{\sqrt{65,4}} = 0,62$$

$$\text{Sim}\left(\vec{d_2}.\vec{q}\right) = \frac{(5x0)+(5x0)+(2x2)}{(\sqrt{25+25+4})(\sqrt{0+0+4})} = \frac{4}{\sqrt{54,4}} = 0,27$$

Contoh di atas memperlihatkan bahwa sesuai dengan perhitungan kosinus, dokumen D2 lebih mirip dengan *query* daripada dokumen D1. Terlihat sudut antara D2 dan Q1 lebih kecil daripada sudut antara D1 dan Q1.

1.2.2 Generalized Vector Space Model (GVSM)

Algoritma *Generalized Vector Space Model* yang dibahas menggunakan konsep ruang vektor. Masukan dari pengguna dan kumpulan dokumen diterjemahkan menjadi vektor-vektor. Kemudian vektor-vektor tersebut dikenakan operasi perkalian titik dan hasilnya menjadi acuan dalam menentukan relevansi masukan pengguna (*query*) terhadap kumpulan dokumen.

Ada beberapa langkah atau proses untuk mendapatkan hasil dari *query* yang dimasukkan, yang disebut algoritma *Generalized Vector Space Model :*

1. Membuang kata depan dan kata penghubung.
2. Menggunakan *stemmer* pada kumpulan dokumen dan *query*, yaitu aplikasi yang digunakan untuk menghilangkan imbuhan (awalan, akhiran).

Contoh : keagungan = agung, keabadian = abadi.

3. Menentukan *min*term untuk menentukan kemungkinan pola frekuensi kata. Panjang *min*term ini didasarkan pada banyak kata yang diinput pada *query*. Kemudian diubah menjadi vektor ortogonal sesuai dengan pola *min*termyang muncul. Kemungkinan pola yang akan muncul adalah :

Tabel 1 Pola Minterm

M_1= (0,0,0)
M_2= (1,0,0)
M_3= (0,1,0)
.....
M_n= (0,0,0)

4. Menghitung banyaknya frekuensi atau kemunculan kata dalam kumpulan dokumen yang sesuai dengan *query*
5. Menghitung *index* term yang dapat dinyatakan dengan :

$$\overrightarrow{Ki} = \frac{\sum_{\forall r, gi(Mr)=1} Cir.\overrightarrow{Mr}}{\sqrt{\sum_{\forall r, gi(Mr)=1} Cir^2}} \quad (2)$$

Dimana :

$\overrightarrow{Ki}$: *Index* term ke-i

$\overrightarrow{Mr}$: vektor ortogonal sesuai pola *min*termyang terpakai

$C_{i,r}$: Faktor korelasi antara *Index* term ke-i dengan minterm r

Sedangkan faktor korelasi sebagai berikut :

$$C_{i,r} = \sum_{d_j | g_i(\vec{d_j}) = g_i(M_r)} W_{i,j} \quad (3)$$

Dimana:

$C_{i,r}$: Faktor korelasi antara *Index* term i dengan minterm r

$W_{i,j}$: Berat *Index* term i pada dokumen j

$g_i(M_r)$: bobot *Index* term K_i dalam minterm M_r

6. Mengubah dokumen dan *query* menjadi vektor

$$\vec{d_j} = \sum_{i=1}^{n} W_{i,j} x \overrightarrow{K_i} \quad (4)$$

$$\vec{q} = \sum_{i=1}^{n} q_i x \overrightarrow{K_i} \quad (5)$$

Dimana :

d_j : vektor dokumen ke-J

$\vec{q}$:vektor *query*

$W_{i,j}$:Berat *Index* term i pada dokumen j

q_i :berat *Index* term pada *query* i

n :jumlah *Index* term

7. Mengurutkan dokumen berdasarkan similiritas, dengan menghitung perkalian vektor

$$\text{Sim}\left(\vec{d_j}.\vec{q}\right) = \frac{\vec{d_j}.\vec{q}}{|\vec{d_j}||\vec{q}|} \quad (6)$$

Dimana :

d_j : vektor dokumen ke-J

$\vec{q}$: vektor *query*

1.2.3 Perbedaan VSM dan GVSM

Untuk dapat membedakan antara metode *vector space model* (VSM) dan *generalized vector space model* (GVSM) diberikan contoh kasus sebagai berikut :

Terdapat Sebuah *query* (q) dan 2 buah dokumen, yaitu dokumen ke-1 (d1) dan dokumen ke-2 (d2) Sebagai berikut :

Tabel 2 Contoh Kasus

Query	Terjadinya Kerusakan Sinyal
Judul dokumen ke-1 (d1)	Kerusakan Pemancar di atap gedung, teknisi memeriksa dua kali
Judul dokumen ke-2 (d2)	Sinyal Kompleks rusak karena gangguan cuaca

1.2.3.1 Menggunakan Vector Space Model

1. Menentukan Minterm

Menentukan minterm berdasarkan banyak kata yang diinput pada *query* dan kemungkinan pola yang muncul . Sebelumnya *query* dilakukan proses *break into token*, *filtration*, dan *stemming* sehingga didapatkan *root word*. Berdasarkan *query* tersebut *minterm* yang dipakai adalah Mx,My,Mz

Tabel 3 Minterm

Mx	terjadi
My	rusak
Mz	sinyal

2. Menghitung Banyaknya frekuensi

Tabel Menghitung banyaknya frekuensi VSM

Tabel 4 Frekuensi Kemunculan Kata Pada Dokumen

	Terjadi	Rusak	Sinyal	Vektor Orthogonal
D1	2	4	0	$\overrightarrow{M_1}$
D2	1	3	3	$\overrightarrow{M_2}$
Q	1	1	1	

3. Menghitung *Similiarity* Dokumen dan *Query*

Sebelum menghitung *similiarity* seluruh term dokumen dan term *query* ditransformasikan kedalam vektor sebagai berikut:

$D_1 = 2T_1 + 4T_2$

$D_2 = 1T_1 + 3T_2 + 3T_3$

$q = T_1 + T_2 + T_3$

Menghitung nilai similiarity berdasarkan vektor :

$$\text{Sim}\left(\overrightarrow{d_1}.\vec{q}\right) = \frac{(2x1)+(4x1)}{\left(\sqrt{2^2+4^2}\right)\left(\sqrt{1^2+1^2+1^2}\right)} = \frac{6}{\sqrt{20}} = 1{,}341$$

$$\text{Sim}\left(\overrightarrow{d_2}.\vec{q}\right) = \frac{(1x1)+(3x1)+(3x1)}{\left(\sqrt{1^2+3^2+3^2}\right)\left(\sqrt{1^2+1^2+1^2}\right)} = \frac{7}{\sqrt{19}} = 1{,}605$$

Berdasarkan hasil perhitungan *similiarity* antara dokumen dan *query* , dapat disimpulkan bahwa dokumen yang memiliki persamaan yang dekat dengan *query* adalah :

1. Dokumen 2 (D_2) = 1,605
2. Dokumen 1 (D_1) = 1,341

Dikarenakan nilai *similiarity* dokumen dua lebih besar dibandingkan dengan nilai *similiarity* dokumen 1 (Sim $\left(\overrightarrow{d_2}.\vec{q}\right)$ >Sim $\left(\overrightarrow{d_1}.\vec{q}\right)$).

1.2.3.2 Menggunakan Generalized Vector Space Model

1. Menentukan Minterm

Menentukan minterm berdasarkan banyak kata yang diinput pada *query* dan kemungkinan pola yang muncul . sebelumnya *query* dilakukan proses *break into token*, *filtration*, dan *stemming* sehingga didapatkan *root word*. Berdasarkan *query* tersebut *minterm* yang dipakai adalah Mx,My,Mz

Tabel 5 Minterm

Mx	terjadi
My	rusak
Mz	sinyal

2. Menghitung Banyaknya frekuensi

Menghitung banyaknya frekuensi GVSM

Tabel 6 Frekuensi Kemunculan Kata Pada Dokumen

	terjadi	Rusak	Sinyal	Vektor Orthogonal
D1	2	4	0	$\overrightarrow{M_1}$
D2	1	3	3	$\overrightarrow{M_2}$
Q	1	1	1	

3. Menghitung Korelasi Setiap Term

Tabel 7 Korelasi Setiap Term

$C_{1,1} = 2$	$C_{2,1} = 4$	$C_{3,1} = 0$
$C_{1,2} = 1$	$C_{2,2} = 3$	$C_{3,2} = 3$

4. Menghitung *Index* term

$$\overrightarrow{K_1} = \frac{C1,1\overrightarrow{M_1} + C1,2\overrightarrow{M_2}}{\sqrt{C1,1^2 + C1,2^2}} = \frac{2\overrightarrow{M_1} + 1\overrightarrow{M_2}}{\sqrt{5}}$$

$$\overrightarrow{K_2} = \frac{C2,1\overrightarrow{M_1} + C2,2\overrightarrow{M_2}}{\sqrt{C2,1^2 + C2,2^2}} = \frac{4\overrightarrow{M_1} + 3\overrightarrow{M_2}}{5}$$

$$\overrightarrow{K_3} = \frac{C3,1\overrightarrow{M_1} + C3,2\overrightarrow{M_2}}{\sqrt{C3,1^2 + C3,2^2}} = \frac{3\overrightarrow{M_2}}{\sqrt{9}} = \overrightarrow{M_2}$$

4. Mengubah dokumen dan *query* kedalam bentuk vektor

$$\overrightarrow{d_1} = 2\overrightarrow{K_1} + 4\overrightarrow{K_2}$$
$$= 2\left[\frac{2\overrightarrow{M_1} + 1\overrightarrow{M_2}}{\sqrt{5}}\right] + 4\left[\frac{4\overrightarrow{M_1} + 3\overrightarrow{M_2}}{5}\right]$$
$$= 4{,}988\overrightarrow{M_1} + 3.294\overrightarrow{M_2}$$

$$\overrightarrow{d_2} = 1\overrightarrow{K_1} + 3\overrightarrow{K_2} + 3\overrightarrow{K_3}$$
$$= 1\left[\frac{2\overrightarrow{M_1} + 1\overrightarrow{M_2}}{\sqrt{5}}\right] + 3\left[\frac{4\overrightarrow{M_1} + 3\overrightarrow{M_2}}{5}\right] + 3\overrightarrow{M_2}$$
$$= 3{,}294\overrightarrow{M_1} + 5{,}247\overrightarrow{M_2}$$

$$\vec{q} = 1\overrightarrow{K_1} + 1\overrightarrow{K_2} + 1\overrightarrow{K_3}$$
$$= 1\left[\frac{2\overrightarrow{M_1} + 1\overrightarrow{M_2}}{\sqrt{5}}\right] + 1\left[\frac{4\overrightarrow{M_1} + 3\overrightarrow{M_2}}{5}\right] + 1\overrightarrow{M_2}$$
$$= 1{,}694\overrightarrow{M_1} + 2{,}047\overrightarrow{M_2}$$

5. Mengubah dokumen dan *query* kedalam bentuk vektor

$$\overrightarrow{d_1} = 2\overrightarrow{K_1} + 4\overrightarrow{K_2}$$
$$= 2\left[\frac{2\overrightarrow{M_1} + 1\overrightarrow{M_2}}{\sqrt{5}}\right] + 4\left[\frac{4\overrightarrow{M_1} + 3\overrightarrow{M_2}}{5}\right]$$
$$= 4{,}988\overrightarrow{M_1} + 3.294\overrightarrow{M_2}$$

$$\overrightarrow{d_2} = 1\overrightarrow{K_1} + 3\overrightarrow{K_2} + 3\overrightarrow{K_3}$$
$$= 1\left[\frac{2\overrightarrow{M_1} + 1\overrightarrow{M_2}}{\sqrt{5}}\right] + 3\left[\frac{4\overrightarrow{M_1} + 3\overrightarrow{M_2}}{5}\right] + 3\overrightarrow{M_2}$$
$$= 3{,}294\overrightarrow{M_1} + 5{,}247\overrightarrow{M_2}$$

$$\vec{q} = 1\overrightarrow{K_1} + 1\overrightarrow{K_2} + 1\overrightarrow{K_3}$$
$$= 1\left[\frac{2\overrightarrow{M_1} + 1\overrightarrow{M_2}}{\sqrt{5}}\right] + 1\left[\frac{4\overrightarrow{M_1} + 3\overrightarrow{M_2}}{5}\right] + 1\overrightarrow{M_2}$$
$$= 1{,}694\overrightarrow{M_1} + 2{,}047\overrightarrow{M_2}$$

6. Menghitung Similaritas dokumen dan meranking

$\text{Sim}(\vec{d_1}.\vec{q}) = \frac{(4,988x1,694)+(3,294x2,047)}{(\sqrt{4,988^2+3,294^2})(\sqrt{1,694^2+2,047^2})}$=0,9565

5

$\text{Sim}(\vec{d_2}.\vec{q}) = \frac{(3,294x1,694)+(5,247x2,047)}{(\sqrt{3,294^2+5,247^2})(\sqrt{1,694^2+2,047^2})}$=0,991

46

Berdasarkan hasil *Similiarity* antara dokumen dan *query* maka dapat disimpulkan bahwa urutan dokumen yang sesuai dengan *query* adalah :

1. Dokumen 2 (D_2) = 0,99146
2. Dokumen 1 (D_1) = 0,95655

Dikarenakan nilai *similiarity* dokumen dua lebih besar dibandingkan dengan nilai *similiarity* dokumen 1 (Sim $(\vec{d_2}.\vec{q})$ >Sim $(\vec{d_1}.\vec{q})$) .

Berdasarkan contoh kasus diatas dapat disimpulkan bahwa perbedaan antara *vector space model* dan *generalized vector space model* terdapat pada perhitungan korelasi antar *query* dan dokumen. Dimana pada *generalized vector space model* semua term dijadikan vektor orthogonal untuk menghitung *Index* term dan setelah itu setiap term pada dokumen digeneralisasi menjadi vektor orthogonal dengan mengkalikan hasil *Index* term dengan term dokumen dan *query*, yang kemudian setiap vektor tersebut dikenakan operasi perkalian titik dan hasilnya menjadi acuan dalam menentukan relevansi masukan pengguna (*query*) terhadap kumpulan dokumen.

1.2.4 Preprocessing

Pada tahapan *preprocessing*, setiap dokumen (termasuk *query*) direpresentasikan menggunakan model *bag-of-words* yang mengabaikan urutan dari kata-kata di dalam dokumen, struktur sintaktis dari dokumen dan kalimat. Dokumen ditransformasi ke dalam suatu "tas" berisi kata-kata independen. Term disimpan dalam suatu *database* pencarian khusus yang ditata sebagai sebuah *inverted index*. *Index* ini merupakan konversi dari dokumen asli yang mengandung sekumpulan kata ke dalam daftar kata yang berasosiasi dengan dokumen terkait dimana kata-kata tersebut muncul.

Preprocessing merepresentasikan koleksi dokumen kedalam bentuk tertentu untuk memudahkan dan mempercepat proses pencarian dan penemuan kembali dokumen yang relevan. Pembangunan *index* dari koleksi dokumen merupakan tugas pokok pada tahapan preprocessing di dalam IR. Kualitas *index* mempengaruhi efektifitas dan efisiensi sistem IR. *index* dokumen adalah himpunan term yang menunjukkan isi atau topik yang dikandung oleh dokumen. *Index* akan membedakan suatu dokumen dari dokumen lain yang berada di dalam koleksi. Ukuran *index* yang kecil dapat memberikan hasil buruk dan mungkin beberapa item yang relevan terabaikan. *index* yang besar memungkinkan ditemukan banyak dokumen yang relevan tetapi sekaligus dapat menaikkan jumlah dokumen yang tidak relevan dan menurunkan kecepatan pencarian (*searching*).

Pembuatan *inverted index* harus melibatkan konsep *linguistic processing* yang bertujuan mengekstrak term-term penting dari dokumen yang direpresentasikan sebagai *bag-of-words*. Konsep linguistic processing terdiri dari tokenizing, filtration (stop list),stemming, dan *parse query.*

1.2.4.1 Tokenizing

Tokenization adalah proses memisahkan deretan kata di dalam kalimat, paragraf atau halaman menjadi *token* atau potongan kata tunggal atau *termmed word* yang berdiri sendiri. Di dalam *tokenizing* karakter dan symbol selain a-z dihilangkan, pemecahan kalimat dan kata dilakukan berdasarkan pada spasi di dalam kalimat tersebut. Tahapan ini juga menghilangkan karakter-karakter tertentu seperti tanda baca dan mengubah semua *token* ke bentuk huruf kecil (*lower case*).

Contoh proses *tokenizing*

Input:

Sinyal adalah besaran fisis yang berubah menurut waktu, ruang, atau variabel-variabel bebas lainnya.

Output:

sinyal adalah besaran fisis yang berubah menurut waktu ruang atau variabel variabel bebas lainnya

1.2.4.2 Filtration

Filtration atau *stop word removal* merupakan merupakan proses lanjutan dari *tokenizing* di dalam *preprocessing* kalimat. Proses *filtration* merupakan proses untuk menghilangkan kata yang 'tidak relevan' pada hasil *parsing* sebuah dokumen teks dengan cara membandingkannya dengan *stoplist* yang ada. *Stoplist* disebut juga dengan *stopword*. *Stoplist* berisi sekumpulan kata yang 'tidak relevan', namun sering sekali muncul dalam sebuah dokumen. Dengan kata lain *Stoplist* berisi sekumpulan *stopword.*

Stopword adalah daftar kata-kata yang tidak dipakai di dalam pemrosesan bahasa alami. Hasil penelitian sebelumnya menyatakan bahwa penggunaan *stopword* meningkatkan kemampuan pemrosesan bahasa alami. Kata-kata hasil tokenisasi yang termasuk dalam *stopword* selanjutnya dihilangkan.

Sebelum Filtration:

Secara matematis, sinyal adalah fungsi dari satu atau lebih variabel independen. Proses ini dilakukan melalui pemodelan sinyal.

Sesudah Filtration:

matematis sinyal fungsi satu lebih variable independen proses dilakukan pemodelan sinyal.

1.2.4.3 Stemming

Stemming adalah proses pencarian bentuk dasar suatu kalimat dengan cara menghilangkan

imbuhannya. *Stemming* merupakan suatu proses yang terdapat dalam sistem IR yang mentransformasi kata-kata yang terdapat dalam suatu dokumen ke kata-kata akarnya (*root word*) dengan menggunakan aturan-aturan tertentu.
Stemming sangat penting dalam mendukung efektivitas pencarian informasi dalam bahasa Indonesia, penerjemahan dokumen, dan pencarian dokumen teks. Imbuhan bahasa Indonesia lebih kompleks dari pada bahasa inggris karena di dalam bahasa Indonesia terdapat awalan (*prefiks*), *infiks* (sisispan), akhiran (*sufiks*), konfiks (gabungan *prefiks* dan *sufiks*). Sehingga stemming bahasa Indonesia harus mampu menemukan akar kata sesuai dengan aturan baku bahasa Indonesia.
Contoh proses Stemming :
Sebelum Stemming:
Matematis sinyal berfungsi satu atau lebih variabel independen maka proses dilakukan pemodelan sinyal
Setelah Stemming:
matematis sinyal fungsi satu atau lebih variable independen maka proses laku model sinyal

1.2.4.4 Searching Process

Setelah proses *preprocessing* dilakukan, selanjutnya adalah melakukan *searching process*. *Searching process* terbagi menjadi dua tahapan besar yaitu parse *query* dan tahapan pemodelan menggunakan *generalized vector space model*. Gambar 2 adalah gambar ilustrasi proses pencarian dalam information retrieval.

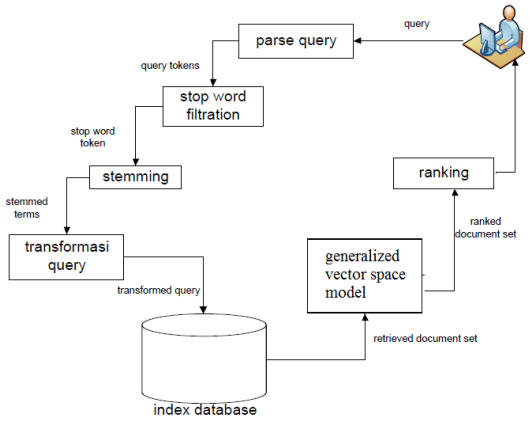

Gambar 2 Skema Searching Proses

Parse *query* adalah tahapan preprocessing yang merubah kalimat *query* kedalam kelompok kata (term) dengan menggunakan beberapa tahapan yaitu :

1. Tokenizing

Tokenizing adalah proses pengenalan *token* yang terdapat dalam rangkaian teks. Proses tokenisasi adalah pemecahan sebuah kalimat menjadi kata(*token*) yang berdiri sendiri. Di dalam *tokenizing* karakter dan symbol selain a-z dihilangkan, pemecahan kalimat dan kata dilakukan berdasarkan pada spasi di dalam kalimat tersebut.

2. Proses *Stopword filtration*

Token-token *query* yang telah dihasilkan pada proses parse *query* kemudian di filter melalui proses pembuangan *token* yang termasuk *Stopword.*

3. Proses *Stemming*

Setelah proses *filtering* pada *Stop Word Filtration* maka token-token *query* yang dihasilkan akan dirubah ke bentuk dasarnya menjadi *stemmed term query*.

Sistem akan membandingkan *Stemmed* term *query* yang dihasilkan tersebut dengan koleksi dokumen sehingga mengembalikan dokumen-dokumen yang relevan. Setelah proses *parse query* dilakukan tahapan selanjutnya adalah memodelkan *query* dengan kumpulan term menggunakan salah satu metode dari information retrieval. Metode yang digunakan pada penelitian ini adalah metode *Generalized Vector Space* model. Tiap term atau kata yang ditemukan pada dokumen dan *query* diberi bobot dan disimpan sebagai salah satu elemen vektor dan dihitung nilai kemiripan antara *query* dan dokumen. Setelah itu perankingan dokumen dapat dilakukan berdasarkan kemiripan antara *query* dan dokumen.

2. ISI PENELITIAN

2.1 Perancangan Sistem

IR merupakan bidang yang mengkaji metode-metode di dalam pencarian dokumen berdasarkan representasi kebutuhan informasi berupa kata kunci atau *keyword*. Untuk itu penelitian ini akan menggunakan metode *Generalized Vector Space Model* pada aplikasi *Information Retrieval*. Pada perancangan aplikasi *information retrieval* ini dilakukan desain aplikasi *information retrieaval* menggunakan metoda *generalized vector space model*. Adapun deskripsi singkat dari sistem *information retrieval* yang akan dibangun ini ditunjukan pada gambar berikut.

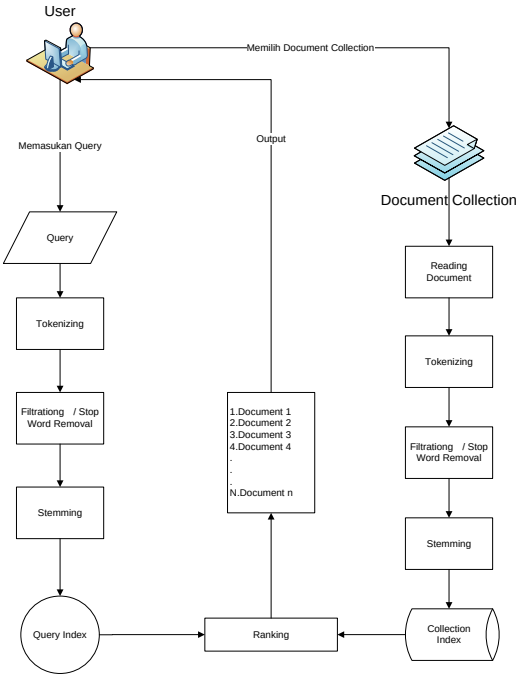

Gambar 3 Rancangan Information Retrieval

Input dari perangkat lunak ini adalah koleksi dokumen berupa *file* text berformat *.pdf dan *query* yang dimasukan oleh pengguna untuk mendapatkan urutan dokumen yang sesuai dengan keinginan pengguna. *Output* dari sistem *information retrieaval* ini adalah *list* dokumen yang sesuai dengan pencarian yang dimasukan oleh pengguna, *list* yang ditampilkan dimulai dari dokumen yang memiliki bobot tertinggi yang sesuai dengan tingkat kemiripan dengan *query* hingga bobot dokumen yang terendah. setiap *list* dapat dilihat sebagai *preview* dan juga dapat dilihat dengan membuka dokumen tersebut berformat *.pdf dengan menggunakan aplikasi *pdf reader*.
Pada aplikasi *information retrieval* ini terdapat dua proses operasi, proses pertama dimulai dari koleksi dokumen dan proses kedua dimulai dari *query* yang dimasukan oleh pengguna. Setiap dokumen yang berada pada *document collection* (folder *file*) akan dibaca oleh sistem. Dokumen-dokumen yang dapat dibaca oleh sistem berformat *.pdf.

2.2 Kasus dan Hasil Pengujian

Untuk menguji ketepatan dan keakuratan aplikasi ini, dilakukan pengujian dengan menghitung nilai precision dan nilai recall pada setiap pencarian, dimulai dari dokumen yang berjumlah 10 hingga dokumen yang berjumlah 100.
Precision adalah rasio jumlah dokumen relevan yang ditemukan dengan total jumlah dokumen yang ditemukan oleh sistem, dengan rumus precision adalah sebagai berikut :

$$\text{Precision} = \frac{|\{a\} \cap \{b\}|}{|\{b\}|} \qquad (7)$$

Diketahui :
a : jumlah dokumen relevan
b : jumlah dokumen yang diuji
Precision mengindikasikan kualitas himpunan jawaban, tetapi tidak memandang total jumlah dokumen yang relevan dalam kumpulan dokumen. Sedangkan Recall adalah rasio jumlah dokumen relevan yang ditemukan kembali dengan total jumlah dokumen dalam kumpulan dokumen yang dianggap relevan, dengan rumus recall adalah sebagai berikut :

$$\text{Recall} = \frac{|\{a\} \cap \{b\}|}{|\{a\}|} \qquad (8)$$

Diketahui :
a : jumlah dokumen relevan
b : jumlah dokumen yang diuji
Hasil pengujian nilai precision dan recall yang di-*retrieve* oleh aplikasi yang telah dilakukan terhadap 10 sampai 100 dokumen dengan kata kunci "**Amplitudo Frekuensi**", dapat dilihat pada tabel berikut.

Tabel 8 Pengujian Nilai Precision dan Recall

Jumlah Dokumen	Dokumen yang ditemukan	P	R	Waktu (Detik)
10	7	7/10	1	3,625
15	9	9/15	1	4,5
20	11	11/20	1	5,8
25	14	14/25	1	7,3
30	17	17/30	1	7,3
35	19	19/35	1	12,5
40	22	22/40	1	8,8
45	26	26/45	1	14,6
50	29	5,8	1	11,5
55	31	31/55	1	18,2
60	31	31/60	1	15,9
65	35	35/65	1	19,6
70	39	39/70	1	20,2
75	43	43/75	1	17,6
85	49	49/85	1	20
90	53	53/90	1	25,9
100	56	0,56	1	25,6

Keterangan :
P : Precision
R : Recall

5. Kesimpulan

Dari hasil pengujian maka Aplikasi IR telah dikembangkan dengan metode GVSM dalam menemukan kembali (*meretrieve*) dokumen sistem dan sinyal yang berformat *.pdf. Aplikasi IR dengan metode GVSM mampu menemukan kembali dokumen sistem dan sinyal tertentu dan sudah

terurut sesuai dengan *query* yang dimasukan pengguna. Aplikasi IR dengan metode GVSM bekerja dengan baik pada jumlah dokumen sedikit maupun pada jumlah dokumen yang banyak.

6. Daftar Pustaka

[1] Alwi, H. (2005). *Kamus Besar Bahasa Indonesia Edisi Ketiga.* Jakarta: Balai Pustaka.
[2] Anugroho, P., Idris Winarno., S., & Nur Rosyid M. Spam Email Classification with Naive.
[3] Asian, J. W., H.E, T., & S.M.M. *Stemming Indonesia.* Australia: RMIT University.
[4] Baeza, R. B. (1999). *Modern Information Retrieval.* United States of America: ACM Press.
[5] Christopher D. Maning, d. (2009). *An Introduction to Information Retrieval.* Cambridge, England: Cambridge University Press.
[6] Han, J. & Kamber, M. (2001). *Data Mining Concepts and Techniques.* USA: Academic Press.
[7] J.Kowalski, G. (2000). *Information Storage and Retrieval Systems: Theory and Implementation.* United States of America.
[8] Kim Hamilton and Russell Miles. (2006). *Learning UML 2.0.* O'Reilly.
[9] Mandala, R. Peningkatan Performansi Sistem Temu-kembali Informasi dengan Perluasan Query secara Otomatis. *Laboratorium Keahlian Informatika Teori*.
[10] Nazief, B. d. Approach to Stemming Algorithm. *Confix-Stripping*.
[11] Pressman, R. *Rekayasa Perangkat Lunak Pendekatan Praktisi.* Yogyakarta: Penerbit Andi.
[12] Salton, G. (1989). *Automatic Text Processing,The Transformation, Analysis, andRetrieval of Information by Computer*. United States of America: Addison – Wesly Publishing Company,Inc. All rights reserved.
[13] Wampler, E. B. *The Essence of Object Oriented Programming with Java and UML*.
Wong, S. W. (1985). *Generalized Vector Space Model in Information Retrieval.* http://140.122.185.120/PastCourses/2003FInformation RetrievalandExtraction/Present_2003F/2003F_GeneralizedVectorSpace ModelInInformationRetrieval.pdf.(diakses pada tanggal 24 Januari 2014).